VBot: trợ lý AI văn phòng, chi phí tháng thấp nhất

Một cloud chính • 2.000 DAU • 5 cấp tác vụ • chất lượng và kiểm soát trước tối ưu chi phí

BẢN NHÁP — CHƯA KHÓA GIÁ

Vấn đề

Tri thức phân tán giữa Google Workspace, Microsoft 365, Notion, Jira, Confluence; agent cần làm việc mà không vượt quyền.

Giải pháp

AWS Singapore, truy cập theo danh tính; RAG lọc ACL, model routing, connector OAuth, sandbox cô lập và phê duyệt thao tác ghi.

Điều kiện thắng

Giảm USD/tháng trong số phương án vượt H1–H8. Không dùng giá khuyến mãi; mỗi dòng giá có bằng chứng và khớp slide–XLSX.

2.000
người dùng/ngày

19
component bắt buộc

99,5%
mục tiêu giờ hành chính

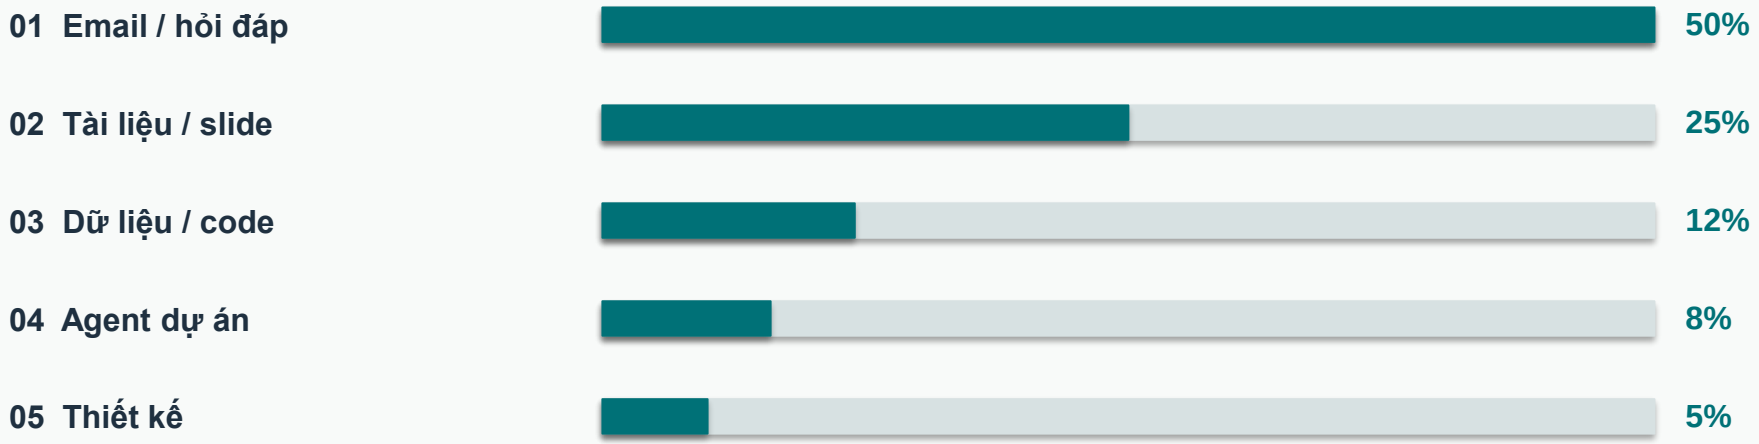
Nguồn: vbot-capstone.html. Đây là thiết kế kiến trúc/báo giá, không phải hệ thống đã triển khai.

Từ 2.000 DAU tới tải giờ cao điểm

10 request/người/ngày và peak ×4 là giả định chung để lập dự toán, chưa được đo

440.000	1.055,56M	301,84M	2,22
request/tháng	input token/tháng	output token/tháng	request/giây peak

CƠ CẤU NĂM CẤP TÁC VỤ



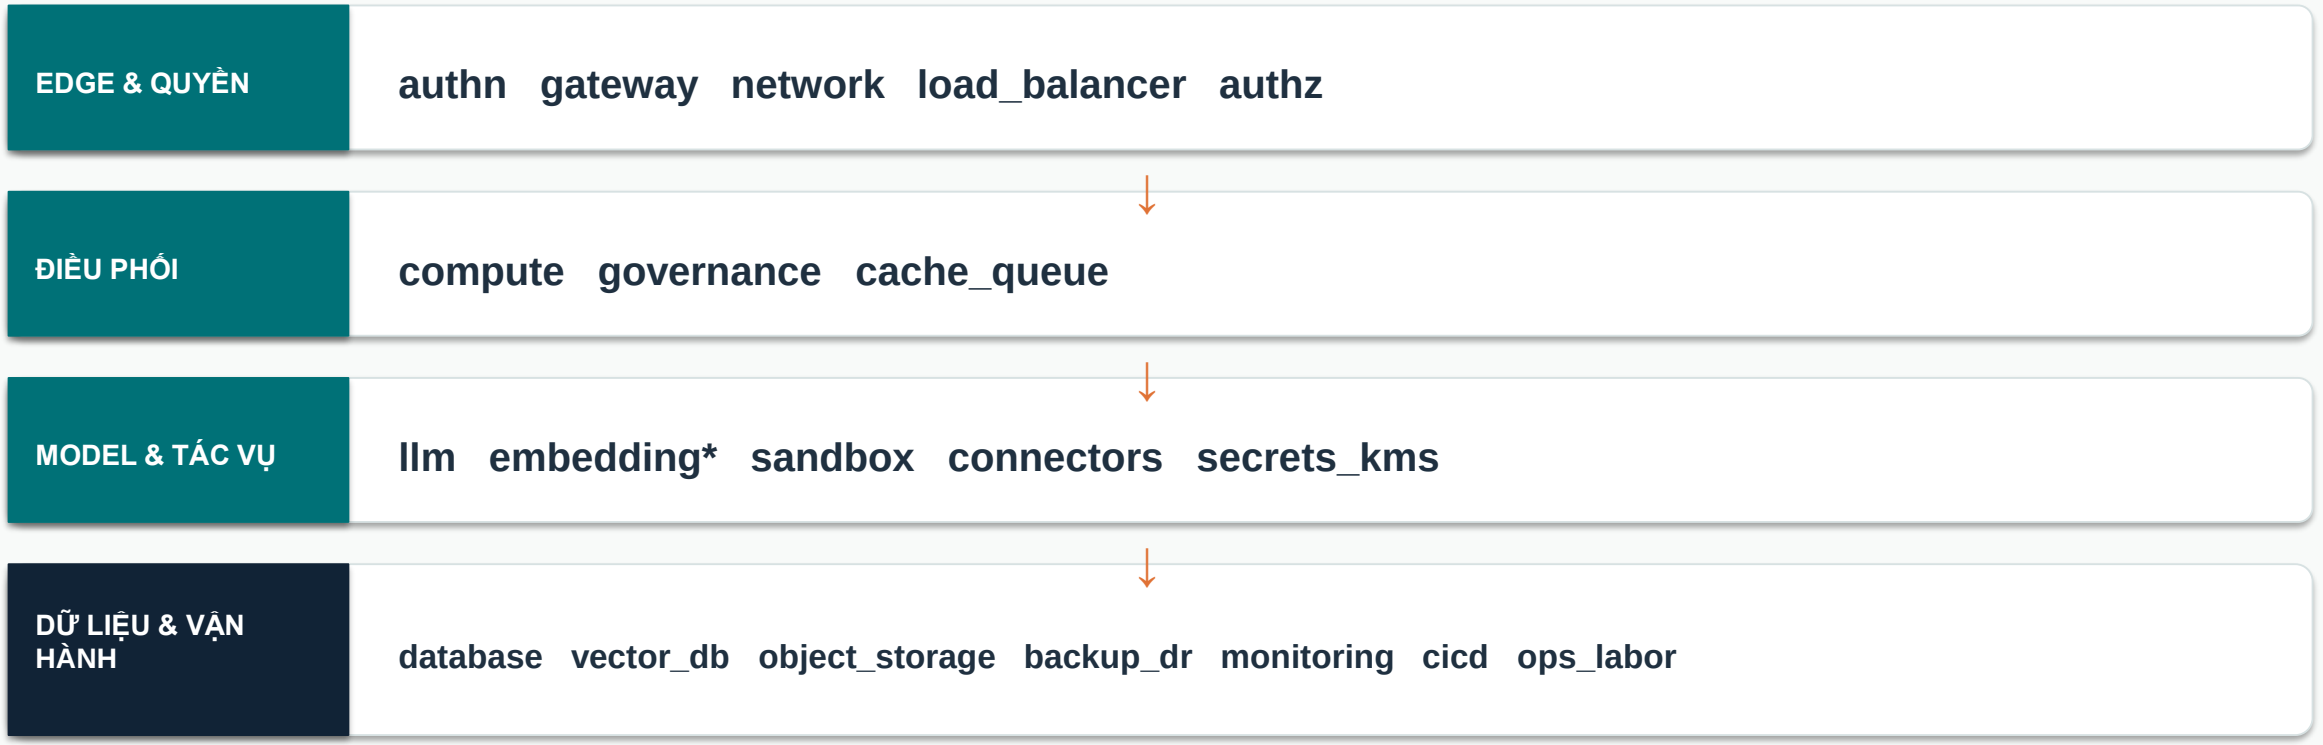
HỆ QUẢ

59.840 sandbox run/tháng
18,1 run đồng thời peak
67 phiên chat peak
220 giờ làm việc/tháng

Công thức: 2.000 × 22 × 10 = 440.000; peak = 440.000 / (220 × 3.600) × 4. Nguồn: dung/ASSUMPTIONS.md.

Một kiến trúc AWS Singapore — đủ 19/19 component

Prod hai AZ, staging tách biệt; Bedrock Nova text định tuyến trong APAC



* embedding là component tùy chọn ngoài 19 mã bắt buộc. API Gateway → VPC link → ALB → orchestrator; Bảo còn chốt SKU/HA.

Mỗi request đi qua quyền, policy và đường trả lời có kiểm soát

Ví dụ: đọc tài liệu nội bộ rồi đề xuất cập nhật Jira

01
SSO + quota
Xác thực phiên, tenant/user, hạn mức.

→

02
RAG theo ACL
Lọc vector; kiểm lại quyền ở nguồn.

→

03
DLP + routing
Che PII; chọn Micro/Pro sau eval.

→

04
Tool hoặc connector
Sandbox không token; ghi Jira cần duyệt.

→

05
Audit + trả lời
Kiểm output, ghi trace, stream kết quả.

Nguyên tắc: model chỉ đề xuất. Policy và người dùng quyết định hành động ghi; payload đổi thì xin duyệt lại.

Nguồn: dung/ARCHITECTURE.md và bao/SECURITY_DESIGN.md.

Route theo độ khó, không hạ chất lượng để giảm giá

Nova Micro / Nova Pro qua Bedrock APAC; cấp 5 mặc định tạo HTML/SVG

CẤP	CÔNG VIỆC	ROUTING ĐỀ XUẤT	REQUEST/THÁNG
Cấp 1	Email, hỏi đáp	90% Micro / 10% Pro	**220.000**
Cấp 2	Tài liệu, slide	50% Micro / 50% Pro	**110.000**
Cấp 3	Bảng tính, code	Pro + sandbox	**52.800**
Cấp 4	Agent nhiều bước	Pro + queue + approval	**35.200**
Cấp 5	Mockup, sơ đồ, minh họa	Micro/Pro → HTML/SVG	**22.000**

Ảnh bitmap ngoài APAC KHÔNG nằm trong baseline; chỉ bật sau duyệt residency và cộng riêng 4.400 ảnh / $176/tháng.

Nguồn: kiet/KIET_MODEL_SERVING.md. Tỉ lệ route là giả định, chưa qua eval.

API managed là baseline; tiết kiệm $774,95/tháng có điều kiện

Chất lượng ≥95% so với Pro theo từng cấp; p95 TTFT ≤3 giây là mục tiêu chưa đo

Micro + Pro

$1.669,00/tháng text

Chọn tạm; chỉ áp dụng tỉ lệ route nếu Micro vượt eval 100 case/cấp.

Toàn bộ Pro

$2.443,95/tháng text

Dễ vận hành hơn, nhưng thêm $774,95/tháng theo workload giả định.

Tự host / hybrid

Chưa định giá GPU Singapore. Ngưỡng lý thuyết ≤$1,143/node-giờ cho 2 node; phải benchmark.

Cổng nghiệm thu ≥95% điểm Pro/cấp • 0 lỗi ACL/PII • load test 2,22 RPS / 30 phút • agent ≤10 phút gồm queue/tool/sandbox

Giá phần text theo AWS Bedrock Price List Singapore; cache hit giả định 0%, không trừ tiền khi chưa đo. Nguồn: kiet/KIET_MODEL_SERVING.md.

RAG chỉ trả tài liệu user được phép xem

Phần này tổng hợp từ kế hoạch và giả định Dũng; chưa có tài liệu bàn giao riêng của Phong

Connectors + OAuth

Google Workspace, Microsoft 365, Outlook, Notion, Jira, Confluence. Đọc theo scope user; ghi chỉ sau approval. Ước lượng 564.960 call/tháng.

RAG + ACL

Index gắn nguồn, tenant, ACL version. Lọc trước truy hồi và kiểm lại tại nguồn; cache key mang quyền. Cohere Embed Multilingual v3 cho query tiếng Việt/Anh.

Workspace riêng

Quota 10 GB/user = trần logic 20 TB; giả định dùng thực 1 GB/user ≈2 TB. Database, vector DB, object storage và queue tách ranh giới giá.

Cần Phong xác nhận: corpus/GB thực, MAU/license, ACL gốc, rate limit connector, replica/index và giá 5 component.

Nguồn: dung/ASSUMPTIONS.md, dung/ARCHITECTURE.md, TEAMMATE_PLAN.md. Số liệu data là giả định quy hoạch.

Code chạy trong môi trường tạm — không mang token, không có egress

59.840 run/tháng · peak ≈18,1 run đồng thời nếu 60 giây/run

01

Stage đúng quyền

Runner nhận input đã lọc ACL; chỉ mount dữ liệu đúng user.

02

Cô lập runtime

Ứng viên gVisor/microVM; non-root, không đặc quyền, không cloud metadata.

03

Giới hạn & hủy

Cấm mạng mặc định; quota CPU/RAM/PID/disk/thời gian; dọn sau chạy.

04

Kiểm artifact

Scan output, DLP và publish qua runner vào workspace đúng chủ.

Chưa chốt runtime/SKU, vCPU/RAM và billing minimum; Bảo phải chứng minh cách chịu peak khi mất một AZ.

Nguồn: bao/SLIDES_8_10.md và bao/SIZING_AND_COST.md.

Model đề xuất; policy và người dùng quyết định

SSO/MFA, RBAC/ABAC, ACL gốc, token vault, DLP và audit 12 tháng

DỮ LIỆU VÀO	Connector/RAG là nguồn không tin cậy → phân loại, kiểm ACL, che PII/secret, chặn prompt injection.
HÀNH ĐỘNG GHI	Preview đích + payload → user xác nhận → kiểm lại scope/quyền → connector thực thi idempotent.
TOKEN & SANDBOX	OAuth ủy nhiệm nằm trong vault KMS; model/sandbox không nhận token; mặc định deny egress.
DỮ LIỆU RA	Guardrail/DLP kiểm kết quả và artifact; audit 12 tháng; đổi model/prompt qua eval gate.

Nguồn: bao/SECURITY_DESIGN.md. Cần kiểm điều khoản xử lý dữ liệu của Bedrock APAC trước khi tuyên bố đáp ứng H1/H5.

Thiết kế cho giờ hành chính; chỉ công bố đạt sau diễn tập

99,5% availability • TTFT p95 ≤3s • agent ≤10 phút • RTO 4h / RPO 1h

Hai AZ + staging

API Gateway/ALB managed; orchestrator hai replica; DB failover; staging tách quyền/dữ liệu. AZ còn lại cần đủ tải hoặc policy giảm tải đã duyệt.

Backup + restore

PITR/backup object, kiểm bản sao và khóa; restore drill đo RTO 4 giờ, RPO 1 giờ. Hai AZ không đồng nghĩa DR khi mất cả region.

Quan sát + FinOps

Trace TTFT/queue/tool, token/user, sandbox, backup age. Cảnh báo 70/90/100% ngân sách; CI/CD staging → eval → canary → rollback.

Trạng thái: chưa có kết quả load test, failover test hay restore drill; các SLO trên là mục tiêu nghiệm thu.

Nguồn: bao/OPERATIONS_AND_ACCEPTANCE.md và dung/ARCHITECTURE.md.

Chưa thể khóa TOTAL: hiện chỉ có phần Kiệt và nhân sự Dũng

Không cộng giả các component chưa có SKU, đơn giá và bằng chứng

Model + embedding + gateway

$1.679,86 / tháng

Baseline không bitmap; giá gateway vẫn cần đối chiếu SKU Singapore.

Nhân sự vận hành

$800,00 / tháng

Giả định 40 giờ × $20; Dũng cần xác nhận ca trực và đơn giá.

Đã có số sơ bộ

$2.479,86 / tháng

KHÔNG PHẢI TOTAL: thiếu data, sandbox, HA, network, backup và bảo mật.

Muốn khóa slide này

Nhận 5 component của Phong + 11 component của Bảo → ghép BaoGia → xác minh bằng chứng → lấy TOTAL, USD/DAU và top 5 trực tiếp từ XLSX.

Đề yêu cầu TOTAL và top 5; slide này cố ý đánh dấu chưa khóa, không dùng làm bản nộp cuối. Nguồn: kiet/KIET_BAOGIA.tsv, dung/DUNG_BAOGIA.tsv.

4.000 DAU: tải gần gấp đôi, chi phí không tự động gấp đôi

Chốt thiết kế sau khi đủ giá và vượt cổng chất lượng H1–H8

880.000
request/tháng

4,44
request/giây peak

119.680
sandbox run/tháng

$3.359,20
phần Kiệt/tháng*

Rủi ro cần xử lý

Geo inference/residency; ACL stale; sandbox peak khi mất AZ; thiếu bằng chứng giá; TTFT và eval chưa đo.

Cổng hoàn thành

Chốt SKU và TOTAL; eval ≥95% từng cấp; load/HA/restore test; đối chiếu PDF với XLSX và chạy validator ĐẠT.

* Giữ mix và đơn giá; corpus index không nhân đôi. Tổng hệ thống phải tính lại từng meter, replica, staging và license.